

1. Loading dei dati

- Importare le matrici raw (formato mtx/csv/tsv/h5) in R
- Creare l'oggetto Seurat con `CreateSeuratObject()`
- Se hai più campioni/dataset: caricarli singolarmente prima di unirli (per poter fare QC dataset-specifico)

2. Controllo qualità (QC) — metriche da calcolare

- **nFeature_RNA**: numero di geni distinti rilevati per cellula (troppo basso → cellula vuota/degradata; troppo alto → possibile doublet)
- **nCount_RNA**: numero totale di conte (UMI) per cellula
- **percent.mt**: percentuale di trascritti mitocondriali (alta → cellula morente/stressata, membrana rotta)
- **percent.hb** (emoglobina): utile per tessuti con contaminazione da globuli rossi
- Visualizzare con violin plot / scatter plot (`FeatureScatter`) per decidere le soglie

3. Filtraggio

- Applicare soglie (nel paper che hai caricato: $nFeature_RNA > 200$, < 5000 , $nCount_RNA < 15000$, $percent.mt < 20\%$, $percent.hb < 5\%$)
- Rimuovere geni rilevati in meno di N cellule (es. < 3 cellule) — geni troppo rari da poter analizzare

4. Rimozione dei doublet

- Passo spesso fatto **prima o insieme** al filtraggio sopra, con tool dedicati come **DoubletFinder**, **scDbIFinder** o **Scrublet** (Python)
- Un doublet è una "cellula" che in realtà è la cattura di due cellule insieme — va rimossa perché falsa il segnale trascrittomico
- Nota: nel paper che hai caricato questo step non è menzionato esplicitamente, ma è buona pratica farlo prima della normalizzazione

5. Normalizzazione

- Log-normalizzazione con fattore di scala (tipicamente 10.000): `NormalizeData()`
- Alternative: `SCTransform` (regressione più sofisticata, gestisce meglio la varianza tecnica)

6. Identificazione delle feature variabili

- `FindVariableFeatures()` con metodo **VST** (variance stabilizing transformation) — tipicamente le top 2.000 feature più variabili tra le cellule

7. Scaling

- ScaleData(): centra e scala i valori di espressione (media 0, varianza 1)
— necessario prima della PCA

8. Riduzione dimensionale (PCA)

- RunPCA() sulle feature variabili scalate
- Scelta del numero ottimale di PC (nel paper: metodo di Piper et al. — soglie su % varianza spiegata dalle singole PC e variazione cumulativa tra PC successive)

9. Integrazione (correzione batch effect)

- Solo se stai unendo più dataset/campioni
- Qui entrano Harmony, RPCA, fastMNN, ecc. di cui abbiamo parlato prima
- Benchmarking con scib-metrics se vuoi confrontare più metodi

10. Clustering

- Costruzione del grafo K-nearest neighbor: FindNeighbors()
- Clustering con algoritmo di Louvain (o Leiden): FindClusters()

11. Visualizzazione non lineare

- **UMAP** (RunUMAP()) o t-SNE per proiettare in 2D e visualizzare i cluster

12. Annotazione dei tipi cellulari

- Identificazione dei marker per cluster: FindAllMarkers()
- Assegnazione manuale basata su marker noti (es. EPCAM per epiteliali, CD3D per T cells) oppure tool automatici (SingleR, STCAT per sottotipi T, come nel paper)
- Spesso fatta a più livelli: annotazione grossolana (level 1: es. Epiteliale/Fibroblasto/Immune) poi via via più fine (level 2, level 3...)

13. Validazione dell'annotazione

- Verifica con violin plot/dot plot dei marker per cluster
- Verifica composizione per fenotipo/dataset (per escludere bias)
- Eventualmente pseudotime (Monocle3) per confermare traiettorie di differenziazione biologicamente plausibili

14. Analisi a valle (downstream)

- Differential expression tra condizioni/gruppi
- Analisi di arricchimento funzionale (GO, pathway)
- Cell-cell communication (es. CellChat, CellPhoneDB)
- Composizione cellulare tra fenotipi/condizioni

